

Dokumentowe bazy danych MongoDB

Bazy danych

Agenda





- NoSQL
- Dokumentowe bazy danych
- MongoDB podstawowe operacje
- Java API do MongoDB
- MongoDB zaawansowane koncepcje ??

Literatura



- P. J. Sadalage, M. Fowler, NoSQL Distilled: A Brief Guide to the Emerging World of Polyglot Persistence, ..., 2013
 - NoSQL Kompedium wiedzy Helion 2014
- K.Banker, MongoDB in Action, Manning 2012
- E.Redmond, J.Wilson, Seven Databases in Seven Weeks, The Pragmatic Bookshelf 2012
- K.Chodorow, MongoDB: The Definitive Guide, O'Reilly 2013
- R.Copeland, MongoDB: Applied Design Patterns, O'Reilly 2013
- K.Seguin, The Little MongoDB Book (available online: http://openmymind.net/mongodb.pdf)
- K.Chodorow, 50 Tips & Tricks for MongoDB Developers, O'Reilly 2011
- K.Chodorow, Scaling MongoDB, O'Reilly 2011

MongoDB





- dokumentowa baza danych (NoSQL)
- bardzo wydajna (implementacja w C++)
- ma wsparcie dla wielu języków programowania (m.in. C, C++, C#, Java, Python, Ruby, Scala...)





https://db-engines.com/

MongoDB – raport Gartner 2015





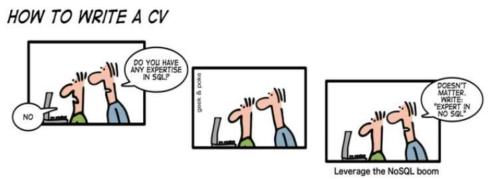


NoSQL





- NoSQL = Not Only SQL
- Klasa systemów DB przechowujących dane w nierelacyjny sposób
- Zwykle nie wymagają definiowania schematu DB
- Właściwości ACID zwykle są mniej restrykcyjnie przestrzegane



http://www.bigdatafarm.com/wp-content/uploads/2013/03/NoSql_joke11.png

Skalowalność



- wertykalna (scale up)
 - zwiększenie zasobów na danym węźle np. zwiększenie pamięci
- horyzontalna (scale out)
 - dodanie kolejnych węzłów do systemu (system rozproszony)

Dlaczego NoSQL?





- nowe zastosowania
- np. eksplozja sieci społecznościowych (Facebook, Twitter) -> potrzeba operowania na b. dużej ilości danych
- rozwój technologii cloud-based (cloud computing, cloud storage -> Amazon S3)
- wraz z większym wykorzystaniem języków dynamicznych (Ruby, Python, Groovy) zaczęto częściej używać dynamicznie typowanych danych z częstymi zmianami schematu

Bazy NoSQL

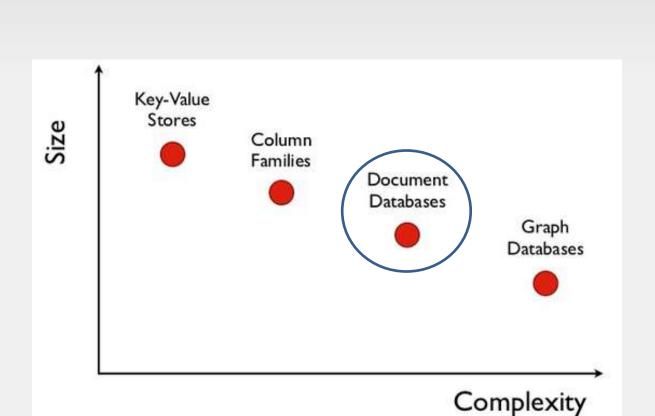




- Zalety
 - nie wymagają schematu
 - łatwiej się skalują
 - wiele implementacji open source
- Wady
 - nowe i często jeszcze niedopracowane narzędzia
 - dane często duplikowane, podatność na niespójności
 - zwykle brak standardu do tworzenia zapytań
 - często trudno zamodelować złożone struktury

Rodzaje baz NoSQL





http://www.slideshare.net/emileifrem/nosql-east-a-nosql-overview-and-the-benefits-of-graph-databases

Bazy dokumentowe





- key-document store
- schema-less
- wsparcie dla map reduce
- przykłady
 - MongoDB
 - CouchDB
 - PostgreSQL ??

Model danych



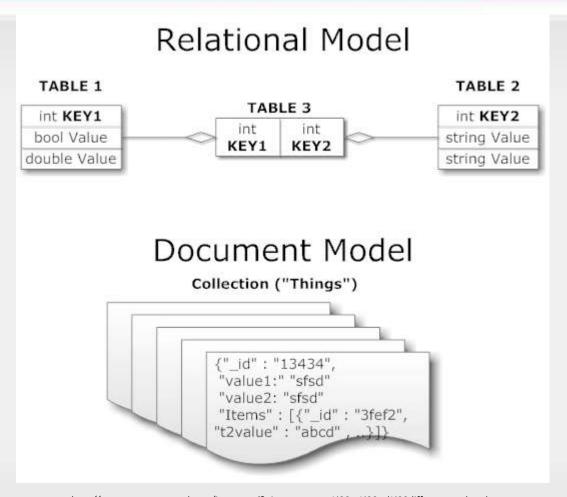


- Pojedyncza instalacja MongoDB może zawierać wiele baz danych
- baza danych zawiera zestaw kolekcji
- kolekcja składa się z dokumentów
- dokument jest zbiorem par klucz-wartość

Model dokumentowy vs model relacyjny



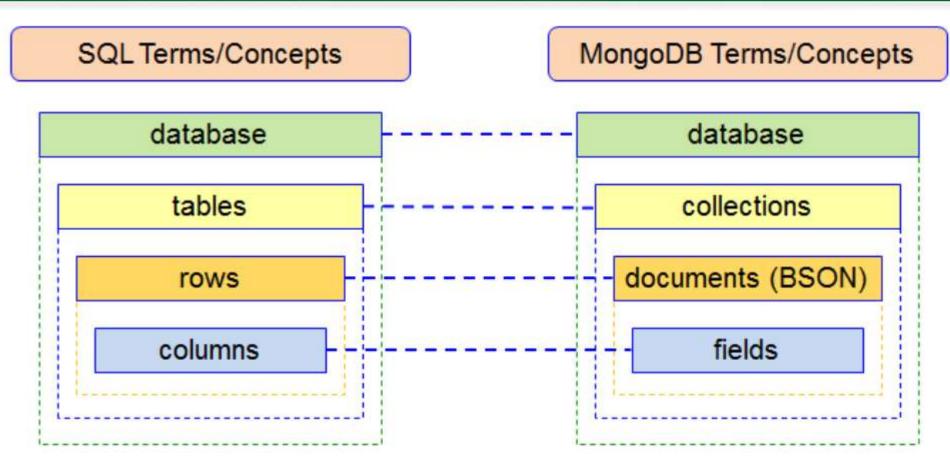




http://www.aaronstannard.com/image.axd?picture=mongo%20vs%20sql%20differences_thumb.png

RDBMS vs MongoDB 1





http://domaintutor.info/invitaciones/sql-vs-mongo-query/

RDBMS vs MongoDB 2



RDBMS	MongoDB
Table	Collection
Row	JSON Document
Index	Index
Join	Embedding & Linking
Partition	Shard

http://sqldev.files.wordpress.com/2011/08/mongo.png

Dokument





- dokumenty w formie JSON (JavaScript Object Notation)
- obiekt nieuporządkowany zbiór par klucz-wartość

```
{
    name: "Jan Kowalski"
}
```

obiekt może być użyty jako złożona wartość w parze klucz-

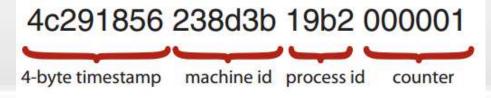
wartość

Id dokumentu





- każdy dokument posiada atrybut _id
- można podać wartość do tego pola
- jeśli nie podana wartość przy wstawianiu dokumentu, zostaje automatycznie ustawiona unikalna wartość typu ObjectId
- musi być unikalne
- format domyślnego id
- 4-byte value representing the seconds since the Unix epoch,
- 3-byte machine identifier,
- 2-byte process id
- 3-byte counter, starting with a random value.



rys z MongoDB in Action

Modelowanie danych 1



References

contact document { _id: <ObjectId2>, user_id: <ObjectId1>, phone: "123-456-7890", email: "xyz@example.com" } access document { _id: <ObjectId3>, user_id: <ObjectId3>, user_id: <ObjectId1>, level: 5, group: "dev" }

VS

Embedded documents

```
{
    _id: <0bjectId1>,
    username: "123xyz",
    contact: {
        phone: "123-456-7890",
        email: "xyz@example.com"
      },
    access: {
        level: 5,
        group: "dev"
    }
}

Embedded sub-
document
}
```

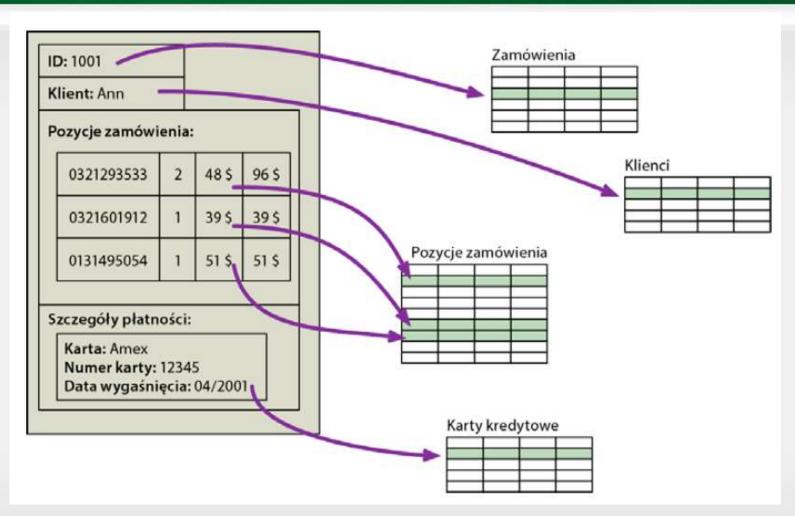
do rozważenia:

- atomowość operacji zapisu (poziom pojedynczego dokumentu)
- rozrost dokumentu (może prowadzić do relokacji na dysku i fragmentacji)
- typowe przypadki użycia
- względy wydajnościowe
- aspekty normalizacji i redundancji danych

Modelowanie danych 2





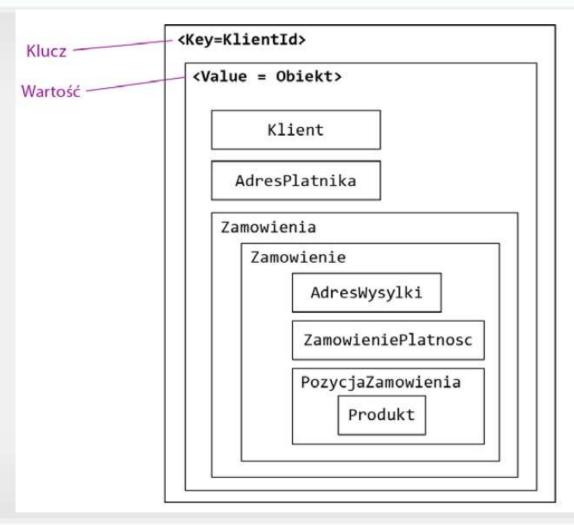


rys z NoSQL Kompedium wiedzy

Modelowanie z myślą o dostępie do danych 1





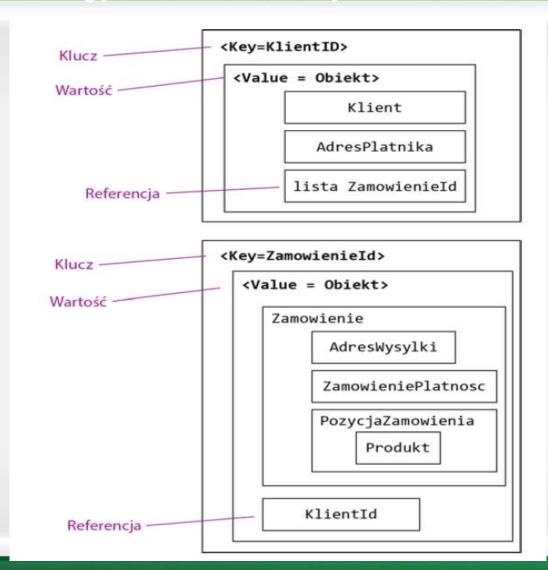


rys z NoSQL Kompedium wiedzy

Modelowanie z myślą o dostępie do danych 2







rys z NoSQL Kompedium wiedzy

Interakcja z MongoDB





- konsola mongo
- zewn. graficzne narzędzia np. Robo 3T/Robomongo
- z poziomu jęz. programowania

Konsola mongo



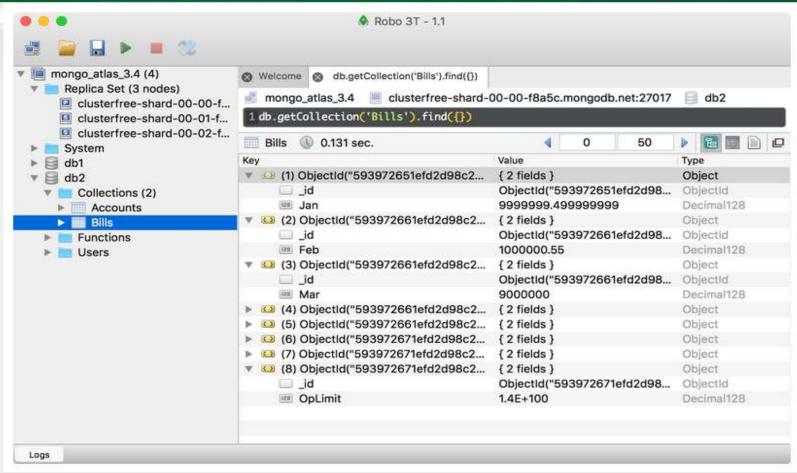


```
λ mongo
MongoDB shell version v3.4.2
connecting to: mongodb://127.0.0.1:27017
MongoDB server version: 3.4.2
Server has startup warnings:
2017-03-07T21:43:07.665+0100 I CONTROL [initandlisten]
2017-03-07T21:43:07.666+0100 I CONTROL [initandlisten] ** WARNING: Access control is not enabled for the database.
2017-03-07T21:43:07.666+0100 I CONTROL [initandlisten] ** Read and write access to data and configuration is unrestricted.
2017-03-07T21:43:07.667+0100 I CONTROL [initandlisten]
```

Robo 3T







rys z https://robomongo.org/

Uruchomienie demona MongoDB





- mongod
- domyślny port: 27017

mongo – uruchomienie konsoli (JavaScript shell)

Praca z konsolą





- wybór bazy: use nazwa_bazy
- nie tworzy się bazy exlicit (tak samo nie ma konieczności tworzenia kolekcji explicit, choć można używając polecenia db.createCollection(nazwa)) – przy wstawianiu dokumentów są od razu tworzone
- lista baz: show dbs
- lista kolekcji: show collections

Operacje zapisu





 wstawianie do kolekcji (kolekcji nie tworzy się wcześniej, tylko wstawiając element do niej)

```
db.cars.insert({
    make: "Opel",
    model: "Astra",
    year: 2010,
    price: 25500,
    advert:{
        date: ISODate("2014-10-25"),
        mail: "test@test.com"
    }
})
```

```
db.cars.insert({
    make: "Ford",
    model: "Focus",
    year: 2005,
    price: 15500,
    features: ["airbags","EPS"],
    advert:{
        date: ISODate("2014-10-08"),
        mail: "test2@test.com"
    }
})
```

```
db.cars.insert({
    make: "Seat",
    model: "Toledo",
    year: 2012,
    price: 35500,
    features: ["airbags","air conditioning"],
    advert:{
        date: ISODate("2014-10-15"),
        phone: "123456"
    }
})
```

Walidacja





```
db.createCollection("students", {
   validator: {
      $jsonSchema: {
         bsonType: "object",
         required: [ "name", "year", "major", "gpa" ],
         properties: {
            name: {
               bsonType: "string",
               description: "must be a string and is required"
           1,
            gender: {
               bsonType: "string",
               description: "must be a string and is not required"
           3.
            year: {
               bsonType: "int",
               minimum: 2017,
               maximum: 3817,
               exclusiveMaximum: false,
               description: "must be an integer in [ 2017, 3017 ] and is required"
            1,
            major: {
               enum: [ "Math", "English", "Computer Science", "History", null ],
               description: "can only be one of the enum values and is required"
            3,
            gpa: {
               bsonType: [ "double" ],
               minimum: 0.
               description: "must be a double and is required"
      1
  1
3)
```

Operacje odczytu





odczytywanie kolekcji

```
db.cars.find()
  cars 0 sec.
   " id" : ObjectId("5467e0638b784aa6a9e7d8bd"),
   "make" : "Seat",
   "model" : "Toledo",
   "year" : 2012,
   "price" : 35500,
   "features" : [
       "airbags",
       "air conditioning"
   "advert" : {
       "date" : ISODate("2014-10-15T00:00:00.000Z"),
       "phone": "123456"
   " id" : ObjectId("5467e0dd8b784aa6a9e7d8be"),
   "make" : "Opel",
   "model" : "Astra",
   "price": 25500,
   "advert" : {
       "date" : ISODate("2014-10-25T00:00:00.000Z"),
       "mail" : "test@test.com"
```

Operacje odczytu 2





odczytywanie kolekcji z dodatkowymi warunkami

```
db.cars.find({year:2005})
      ( 0 sec.
    " id" : ObjectId("5467e3988b784aa6a9e7d8bf"),
    "make" : "Ford",
    "model" : "Focus",
    "year" : 2005,
    "price": 15500,
    "features" : [
        "airbags",
        "EPS"
    "advert" : {
        "date" : ISODate("2014-10-08T00:00:00.000Z")
        "mail" : "test2@test.com"
    " id" : ObjectId("5467e7dc8b784aa6a9e7d8c1"),
    "make" : "Fiat",
    "model" : "Punto",
    "year" : 2005,
    "price": 10000,
    "advert" : {
        "date" : ISODate("2014-11-05T00:00:00.000Z")
```

Operacje odczytu 3 - Projekcje





- odczyt kolekcji z wyborem pól
 - podanie jakie pola mają się znaleźć w wyniku

podanie jakie mają zostać wykluczone

uwaga: nie można łączyć tych 2 sposobów

Operacje odczytu 4





dopasowanie dokładne

dopasowanie "częściowe"

Operacje odczytu 5





jak odwoływać się do zagnieżdżonych pól?

```
db.cars.find({ 'advert.mail': {$exists: true}}, {make:1, model:1, advert:1}
cars 0 0 sec.
   " id" : ObjectId("5467e0dd8b784aa6a9e7d8be"),
   "make" : "Opel",
   "model" : "Astra",
   "advert" : {
       "date" : ISODate("2014-10-25T00:00:00.000Z"),
        "mail" : "test@test.com"
   " id" : ObjectId("5467e3988b784aa6a9e7d8bf"),
   "make" : "Ford",
   "model" : "Focus",
    "advert" : {
        "date" : ISODate("2014-10-08T00:00:00.000Z"),
        "mail" : "test2@test.com"
```

Często używane operatory w zapytaniach





Command	Description
\$regex	Match by any PCRE-compliant regular expression string (or
	just use the // delimiters as shown earlier)
\$ne	Not equal to
\$lt	Less than
\$lte	Less than or equal to
\$gt	Greater than
\$gte	Greater than or equal to
\$exists	Check for the existence of a field
\$all	Match all elements in an array
\$in	Match any elements in an array
\$nin	Does not match any elements in an array
\$elemMatch	Match all fields in an array of nested documents
\$or	or
\$nor	Not or
\$size	Match array of given size
\$mod	Modulus
\$type	Match if field is a given datatype
\$not	Negate the given operator check

Sortowanie





rosnąco

```
db.cars.find({},{model:1,price:1}).sort({price:1})
```

```
cars ( 0 sec.
   " id" : ObjectId("5467e7dc8b784aa6a9e7d8c1"),
   "model" : "Punto",
   "price" : 10000
   " id" : ObjectId("5467e3988b784aa6a9e7d8bf"),
   "model" : "Focus",
   "price" : 15500
   " id" : ObjectId("5467e0dd8b784aa6a9e7d8be"),
   "model" : "Astra",
   "price" : 25500
```

malejąco

```
db.cars.find({}, {model:1, price:1}).sort({price:-1})
cars ( 0 sec.
   " id" : ObjectId("5467e0dd8b784aa6a9e7d8be"),
   "model" : "Astra",
   "price" : 25500
   " id" : ObjectId("5467e3988b784aa6a9e7d8bf"),
   "model" : "Focus",
   "price": 15500
   " id" : ObjectId("5467e7dc8b784aa6a9e7d8c1"),
   "model" : "Punto",
   "price" : 10000
```

Aktualizacja danych





update(criteria,operation)

```
db.cars.update(
     {make: "Seat"},
     {$set: {price:40000}}
        to samo ObjectId
db.cars.update(
 id:ObjectId("5467e0638b784aa6a9e7d8bd")),
price:40000}
```

uwaga na słowo kluczowe \$set

- bez tego podmienia dokument

db.cars.find({ id:ObjectId("5467e0638b784aa6a9e7d8bd")

Często używane operatory przy aktualizacji





przykład dla \$inc

db.cars.find({ id:ObjectId("5467e0638b784aa6a9e7d8bd")}

		cars (0 sec.
Command	Description	/* 0 */ {
\$set	Sets the given field with the given value	"_id" : ObjectId("5467e0638b784aa6a9e7d8bd"),
\$unset	Removes the field	}
Sinc	Adds the given field by the given number	
\$pop	Removes the last (or first) element from an array	
Spush	Adds the value to an array	<pre>db.cars.update({ id:ObjectId("5467e0638b784aa6a9e7d8bd")},</pre>
\$pushAll	Adds all values to an array	{\$inc: {price:5000}}
\$addToSe	Similar to push, but won't duplicate values)
\$pull	Removes matching value from an array	
\$pullAll	Removes all matching values from an array	
		db.cars.find({_id:ObjectId("5467e0638b784aa6a9e7d8b6
		cars © 0 sec.
		/* 0 */

"price" : 45000

" id" : ObjectId("5467e0638b784aa6a9e7d8bd"),

Usuwanie dokumentów i kolekcji





funkcja remove na kolekcji



funkcja drop na kolekcji

```
db.test.drop()
```

Referencje do innych dokumentów





- MongoDB nie wspiera joinów, ale umożliwia przechowywanie w dokumencie referencji do innego dokumentu (złączenia muszą być wykonywane po stronie aplikacji przez pobieranie odpowiednich dokumentów)
- konstrukcja {\$ref:"nazwa_kolekcji", \$id:"id_referencji"}

```
" id" : ObjectId("5467e3988b784aa6a9e7d8bf"),
                                                                         "make" : "Ford",
                                                                         "model" : "Focus",
db.countries.insert({
                                                                         "year" : 2005,
    id: "us",
                                                                        "price" : 15500,
                                                                        "features" : [
    name: "USA"
                                                                            "airbags",
db.cars.update(
                                                                        "advert" : {
{make:"Ford"},
                                                                            "date" : ISODate("2014-10-08T00:00:00.000Z")
{$set: {country: {$ref: "countries", $id: "us"}}}
                                                                            "mail" : "test2@test.com"
                                                                        "country" : {
                                                                            "$ref" : "countries",
```

Referencje do innych dokumentów 2





pobieranie dokumentów z użyciem referencji

```
var ford = db.cars.findOne({make:"Ford"})
db.countries.findOne({_id: ford.country.$id})

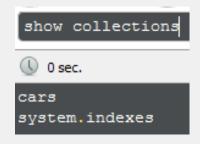
① 0 sec.

/* 0 */
{
    "_id": "us",
    "name": "USA"
}
```

Lista kolekcji



wyświetlenie listy kolekcji



Funkcje 1



Definiowanie funkcji

```
function insertCar(
  make, model, year, price, date) {
    db.cars.insert({
        make:make,
        model:model,
        year:year,
        price:price,
        advert:{
            date:ISODate(date)
        }
    });
}
insertCar("Fiat", "Punto", 2005, 10000, "2014-11-05")
```

Funkcje 2





wyświetlenie treści funkcji

```
db.cars.insert
0 sec.
function (obj, options, _allow_dot) {
    if (!obj) {
        throw "no object passed to insert!";
   if (! allow dot) {
        this. validateForStorage(obj);
    if (typeof options == "undefined") {
        options = 0;
   if (typeof obj. id == "undefined" && !Array.isArray(obj))
       var tmp = obj;
       obj = { id:new ObjectId};
       for (var key in tmp) {
            obj[key] = tmp[key];
    this._db._initExtraInfo();
    this. mongo.insert(this. fullName, obj, options);
    this. lastID = obj. id;
    this. db. getExtraInfo("Inserted");
```

Zapytania

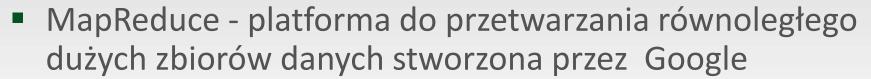




SQL	MongoDB Query Language	
SELECT a,b FROM users	db.users.find({}), {a:1,b:1})	
SELECT * FROM users	db.users.find()	
SELECT * FROM users WHERE age=33	db.users.find({age:33})	
SELECT a,b FROM users WHERE age=33	db.users.find({age:33}, {a:1,b:1})	
SELECT * FROM users WHERE age=33 ORDER BY name	<pre>db.users.find({age:33}).sort({name:1})</pre>	
SELECT * FROM users WHERE age>33	db.users.find({age:{\$gt:33}})	
CELECT + EDOM MANY MUEDE 2001-22	dh waara find/inga-iCan-22111	

Map reduce





krok "map"

- węzeł nadzorczy (master node) pobiera dane z wejścia i dzieli je na mniejsze podproblemy, po czym przesyła je do węzłów roboczych (worker nodes).
- każdy z węzłów roboczych może albo dokonać kolejnego podziału na podproblemy, albo przetworzyć problem i zwrócić odpowiedź do głównego programu.

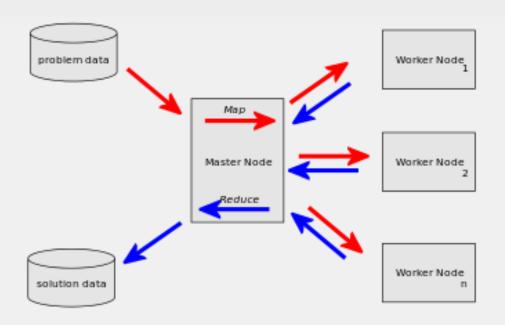
krok "reduce"

 główny program bierze odpowiedzi na wszystkie podproblemy i łączy je w jeden wynik - odpowiedź na główny problem.

https://pl.wikipedia.org/wiki/MapReduce

Map reduce





http://en.wikipedia.org/wiki/MapReduce

Przykład map reduce 1





do wyliczenia:

średnia cena samochodów na poszczególne lata produkcji

map

```
var mapF = function() {
    emit(this.year, this.price);
};
```

reduce

```
var reduceF = function(year, valuesPrices){
    return Array.avg(valuesPrices);
};
```

Przykład map reduce 1 cd





wywołanie

```
db.cars.mapReduce(
    mapF,
    reduceF,
    {out: "avg_price_per_year"}
)
```

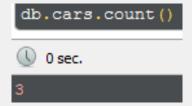
wynik map reduce zapisany jest w kolekcji podanej po nazwie *out*

wynik

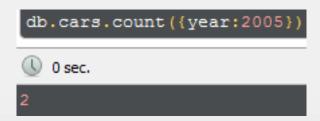




- wbudowane idiomy wyliczania pewnych operacji
- count



count z filtrem – count(query)







distinct(field, query)

uwaga:

Robomongo (po lewej) zwraca dokument JSON, natomiast w konsoli Mongo wynik jest w postaci tablicy (po prawej)

> db.cars.distinct("year")
[2010, 2005]

query można użyć do dodatkowego przefiltrowania

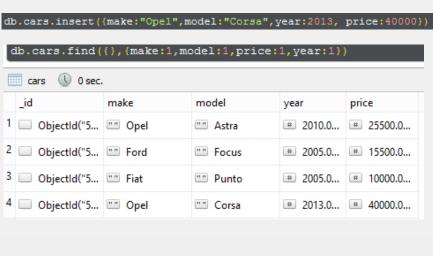
```
> db.cars.distinct("year",{price:{$gt:20000}})
[ 2010 ]
```





group

przygotowanie danych



ile samochodów z każdego roku ma cenę poniżej 40000?

```
db.cars.group({
    key: {year:1},
    cond: {price: {$1t: 40000}},
    initial: {count: 0},
    reduce: function(current, result){result.count += 1}
})

① 0.004 sec.

/* 0 */
{
    "0" : {
        "year" : 2010,
        "count" : 1
    },
    "1" : {
        "year" : 2005,
        "count" : 2
    }
}
```





group cd

średnia cena samochodu w każdym roku spośród tych, co kosztują poniżej 40000

```
db.cars.group({
    key: {year:1},
    cond: {price: {$lt: 40000}},
    initial: {count: 0, sum: 0},
    reduce: function(current, result){
        result.count += 1
        result.sum += current.price
    },
    finalize: function(result) {result.average_price = result.sum/result.count}
})
```

0.004 sec.

```
/* 0 */
{
    "0" : {
        "year" : 2010,
        "count" : 1,
        "sum" : 25500,
        "average_price" : 25500
},
    "1" : {
        "year" : 2005,
        "count" : 2,
        "sum" : 25500,
        "average_price" : 12750
}
```

Indeksy



- podobne do indeksów w RDBMS
- MongoDB wspiera indeksy na dowolne pole w dokumencie lub zagnieżdżonym dokumencie
- indeksy są zdefiniowane na poziomie kolekcji
- indeksy korzystają z B-drzew,
 - są także indeksy do danych geograficznych

tworzenie indeksów: ensureIndex(fields, options)

Przykład działania indeksów





na podstawie MongoDB in Action

for(i=0; i < 2000000; i++){

db.numbers.save({num: i})

```
db.numbers.find({num: {$gt: 15000, $lt: 23000}}).explain()

① 0.808 sec.

/* 0 */
{
    "cursor" : "BasicCursor",
    "isMultiKey" : false,
    "n" : 7999,
    "nscannedObjects" : 2000000,
    "nscanned" : 2000000,
    "nscannedObjectsAllPlans" : 2000000,
    "nscannedAllPlans" : 2000000,
    "scanAndOrder" : false,
    "indexOnly" : false,
    "nYields" : 15625,
    "nChunkSkipe" : 0,
    "millis" : 807,
```

db.numbers.ensureIndex({num: 1}

"nscannedObjectsAllPlans": 7999,

"nscannedAllPlans": 7999,

"scanAndOrder" : false,

"indexOnly" : false,

"nChunkSkir " 0.

"num" : [

"nYields" : 62,

"millis": 6,
"indexBoungs : {

Rodzaje indeksów





- single field indeks na pojedyncze pole dokumentu (także pole zagnieżdżonego dokumentu)
- compound indeks na więcej niż jedno pole dokumentu
- multikey indeks na pole tablicowe (dodaje do indeksu każdą wartość w tablicy)
- geospatial indeks obsługujący zapytania przestrzenne
- text obsługuje zapytania na tekstach w dokumencie (language specific – używa stop words, stemming wyrazów)
- hashed zarządza elementami z hashami wartości

Właściwości indeksów



unikalny (unique) – domyślnie false

```
db.members.ensureIndex( { "user_id": 1 }, { unique: true } )
```

- odrzuca dokumenty ze zduplikowanymi wartościami indeksowanego pola
- rzadki (sparse) domyślnie indeksy są gęste

```
db.addresses.ensureIndex( { "xmpp_id": 1 }, { sparse: true } )
```

- rzadki oznacza, że indeks w sobie zawiera pozycje dla dokumentów, które zawierają dane pole (rzadki => nie zawiera wszystkich dokumentów z danej kolekcji)
- gęsty indeks zawiera pozycje dla wszystkich dokumentów w kolekcji, nawet jeśli nie zawierają one danego pola (przechowuje null dla takich dokumentów)

MongoDB Java API





- podstawowa klasa do połączenia z MongoDB to MongoClient (zastępuje klasę Mongo, po której dziedziczy)
 - główna różnica między tymi 2 klasami: MongoClient domyślnie przy wszystkich operacjach zapisu oczekuje na potwierdzenie z serwera
- Dokument jest reprezentowany przez klasę BasicDBObject
- Java MongoDB driver
 - MongoClient sam zarządza wewnętrzną pulą połączeń do bazy => dla każdego żądania do bazy, wątek Javy otrzymuje wątek z puli, wykonuje operację i zwalnia połączenie (czyli przy wykonywaniu różnych operacji różne połączenia mogą być używane)

Typy danych Java vs MongoDB





- większość (int, double, String...) jest automatycznie mapowana
- Object Ids

za http://docs.mongodb.org/ecosystem/drivers/java-types/

```
ObjectId id = new ObjectId();
ObjectId copy = new ObjectId(id);
```

org.bson.types.ObjectId

wyrażenia regularne

```
Pattern john = Pattern.compile("joh?n", Pattern.CASE_INSENSITIVE);
BasicDBObject query = new BasicDBObject("name", john);

// finds all people with "name" matching /joh?n/i
DBCursor cursor = collection.find(query);
```

java.util.regex.Pattern

Typy danych Java vs MongoDB 2





data

```
Date now = new Date();
BasicDBObject time = new BasicDBObject("ts", now);
collection.save(time);
```

java.util.Date

referencje bazodanowe

```
DBRef addressRef = new DBRef(db, "foo.bar", address_id);
DBObject address = addressRef.fetch();

DBObject person = BasicDBObjectBuilder.start()
        .add("name", "Fred")
        .add("address", addressRef)
        .get();
collection.save(person);

DBObject fred = collection.findOne();
DBRef addressObj = (DBRef)fred.get("address");
addressObj.fetch()
```

com.mongodb.DBRef

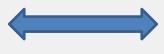
Typy danych Java vs MongoDB 3





embedded documents

```
{
    "x":{
    "y":3
}
```



```
BasicDBObject y = new BasicDBObject("y", 3);
BasicDBObject x = new BasicDBObject("x", y);
```

arrays

Dowolny obiekt dziedziczący po interfejsie List w Javie będzie odwzorowany na array

```
{
    "x" : [
        1,
        2,
        {"foo" : "bar"},
        4
    ]
}
```

```
ArrayList x = new ArrayList();
x.add(1);
x.add(2);
x.add(new BasicDBObject("foo", "bar"));
x.add(4);
BasicDBObject doc = new BasicDBObject("x", x);
```



tworzenie połączenie i uzyskanie dostępu do bazy danych

za http://docs.mongodb.org/ecosystem/tutorial/getting-started-with-java-driver/

```
MongoClient mongoClient = new MongoClient();
// or
MongoClient mongoClient = new MongoClient( "localhost" );
// or
MongoClient mongoClient = new MongoClient( "localhost" , 27017 );
DB db = mongoClient.getDB( "mydb" );
```

pobieranie kolekcji z bazy

```
Set<String> colls = db.getCollectionNames();

DBCollection coll = db.getCollection("testCollection");
```





wstawianie dokumentu do bazy

wstawianie wielu dokumentów

```
for (int i=0; i < 100; i++) {
    coll.insert(new BasicDBObject("i", i));
}</pre>
```

zliczenie dokumentów w kolekcji

```
System.out.println(coll.getCount());
```





wyszukiwanie dokumentów

```
db.things.find({i: 71});
db.things.find({j: {$ne: 3}, k: {$gt: 10} });
```

```
BasicDBObject query = new BasicDBObject("i", 71);
 cursor = coll.find(query);
 try {
   while(cursor.hasNext()) {
       System.out.println(cursor.next());
 } finally {
    cursor.close():
query = new BasicDBObject("j", new BasicDBObject("$ne", 3))
        .append("k", new BasicDBObject("$gt", 10));
cursor = coll.find(query);
try {
   while(cursor.hasNext()) {
        System.out.println(cursor.next());
} finally {
    cursor.close();
```

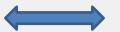




aggregation framework

```
    First operation:

     $match: { type: "airfare"}
2. Piped into:
     Sproject: [ department: 1, amount: 1 ]
Piped into:
     $group: { _1d: "$department",
               average: { savg: "samount" } }
4. Piped into
     Ssort: [ "Samount": -1 ]
```



db.coll.aggregate([

```
// create our pipeline operations, first with the $match
                     DBObject match = new BasicDBObject("$match", new BasicDBObject("type", "airfare"));
                     // build the $projection operation
                     DBObject fields = new BasicDBObject("department", 1);
                     fields.put("amount", 1);
                     fields.put("_id", 0);
                     DBObject project = new BasicDBObject("$project", fields );
                     // Now the $group operation
                     DBObject groupFields = new BasicDBObject( "_id", "$department");
                     groupFields.put("average", new BasicDBObject( "$avg", "$amount"));
                     DBObject group = new BasicDBObject("$group", groupFields);
                     // Finally the $sort operation
                     DBObject sort = new BasicDBObject("$sort", new BasicDBObject("amount", -1));
                     // run aggregation
                     List<DBObject> pipeline = Arrays.asList(match, project, group, sort);
                     AggregationOutput output = coll.aggregate(pipeline);
                                                 for (DBObject result : output.results()) {
                                                     System.out.println(result):
{$match: {type: "airfare"}},
{$project: {department:1, amount: 1}},
{$group: { id:"$department"},
             average: {$avg: "$amount"}},
{$sort: {"$amount":-1}}
```





map reduce

przykład za http://www.javacodegeeks.com/2012/06/mapreduce-with-mongodb.html

```
DBCollection books = db.getCollection("books");
```

```
String map = "function() { "+
          "var category; " +
          "if ( this.pages >= 250 ) "+
          "category = 'Big Books'; " +
          "else" +
                                                                                     wyrażenia JavaScript
          "category = 'Small Books'; "+
          "emit(category, {name: this.name});}"
String reduce = "function(key, values) { " +
                         "var sum = 0;
                         "values.forEach(function(doc) { " +
                         "sum += 1; "+
                         "}); " +
                         "return {books: sum};} ";
MapReduceCommand cmd = new MapReduceCommand(books, map, reduce,
  null, MapReduceCommand.OutputType.INLINE, null);
MapReduceOutput out = books.mapReduce(cmd);
for (DBObject o : out.results()) {
 System.out.println(o.toString());
```

Odwzorowanie klas Javy na kolekcje





dziedziczenie klasy po BasicDBObject

```
public class Address extends BasicDBObject {
   public Address() {
   public Address(String streetName, String postalCode, String place, String countr
y) {
   put("street", streetName);
   put("postalcode", postalCode);
   put("place", place);
   put("country", country);
}

public String place() {
   return (String) get("place");
}
```

http://blog.knuthaugen.no/2010/07/comparing-mongodb-java-frameworks.html

```
Mongo m = new Mongo( "127.0.0.1" , 27017 );
testDb = m.getDB( "test" );
persons = testDb.getCollection("persons");
persons.setObjectClass(Person.class);
```

Odwzorowanie klas Javy na kolekcje 2





implementacja przez klasę interfejsu DBObject

```
public Object put(String s, Object o) { }
public void putAll(OBObject dbObject) { }
public void putAll(Map map) { }
public Object get(String s) { }
public Map toMap() { }
public Object removeField(String s) { }
public boolean containsKey(String s) { }
public boolean containsField(String s) { }
public Set<String&gt; keySet() { }
public void markAsPartialObject() { }
public boolean isPartialObject() { }
```

rys. http://blog.knuthaugen.no/2010/07/comparing-mongodb-java-frameworks.html

```
public class Tweet implements DBObject
   /* ... */
}
```

```
Tweet myTweet = new Tweet();
myTweet.put("user", userId);
myTweet.put("message", msg);
myTweet.put("date", new Date());
collection.insert(myTweet);
```

```
przykład za http://docs.mongodb.org/ecosystem/tutorial/use-java-dbobject-to-perform-saves/
collection.setObjectClass(Tweet.class);
```

```
Tweet myTweet = (Tweet)collection.findOne();

Tweet myTweet = (Tweet)collection.findOne();

myTweet.put("message", newMsg);
```

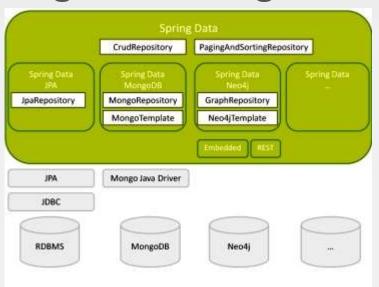
collection.save(myTweet);

Odwzorowanie klas Javy na kolekcje 3





Spring Data MongoDB



http://projects.spring.io/spring-data-mongodb/

Hibernate OGM (Object/Grid Mapper)

http://hibernate.org/ogm/

Replikacja



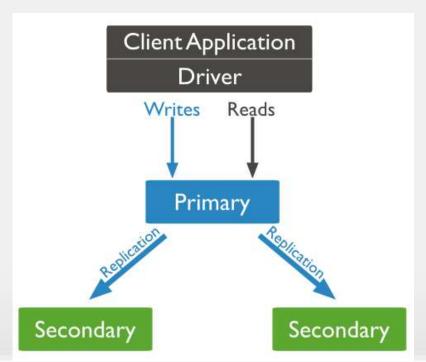
- proces synchronizacji danych na wielu serwerach
- cel
 - redundancja danych
 - większa dostępność danych (umożliwia zmniejszenie czasu na przywrócenie działania usługi po awarii)
 - zwiększa przepustowość odczytu danych (klienci mogą równolegle odczytywać dane z różnych replik)

Repliki w MongoDB





- zbiór replik jest grupą instancji uruchomionych demonów mongod, które hostują ten sam zbiór danych
- podział na primary (jeden) i secondaries (reszta)



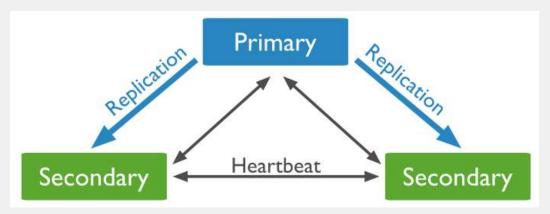
http://docs.mongodb.org/manual/core/replication-introduction/

Repliki w MongoDB 2





 repliki nasłuchują na komunikaty heartbeat, a gdy primary ma awarię jest wybierany nowy primary z pozostałych przez głosowanie

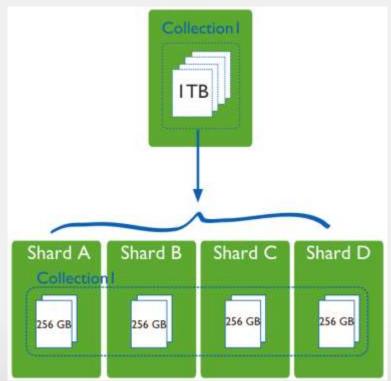


http://docs.mongodb.org/manual/core/replication-introduction/

Sharding



 horizontal scaling, podział przechowywanych danych na wiele maszyn



http://docs.mongodb.org/manual/core/sharding-introduction/

Sharding w MongoDB

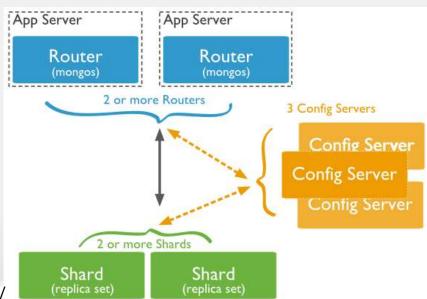




- Komponenty sharded cluster:
 - shards przechowują dane (ze względów wysokiej dostępności i spójności danych shardy często są zbiorami replik)
 - query routers (mongos instances) są interfejsem dla aplikacji klienta, kierują
 zapytania do odpowiednich shardów i zwracają wynik zapytań do klienta (klient wysyła zapytanie do jednego query routera, ale zwykle te routery są

zwielokrotnione)

 config servers – przechowują metadane dotyczące klastru (query routers używają tych metadanych do wyboru odpowiednich shardów)



http://docs.mongodb.org/manual/core/sharding-introduction/

Sharding w MongoDB 2



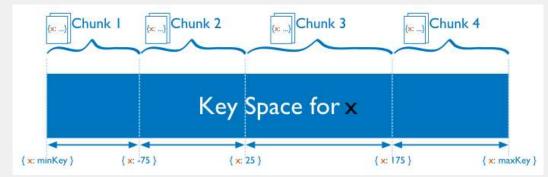
- Partycjonowanie danych odbywa się na poziomie kolekcji z wykorzystaniem shard key
- shard key jest wybierany ręcznie (indeksowane pole lub indeksowany compound – istniejące w każdym dokumencie w kolekcji)
- shard key jest dzielony na części (chunks) i rozdystrybuowany na shardach

Sharding w MongoDB 3

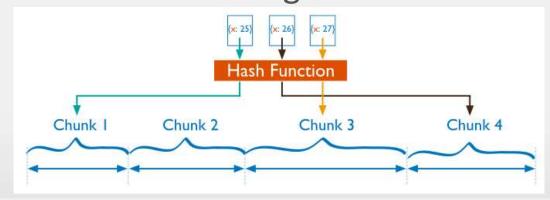




- Sposoby partycjonowania
 - range based sharding



hash based sharding



http://docs.mongodb.org/manual/core/sharding-introduction/

Transakcyjność



- MongoDB zapewnia atomowość operacji na poziomie pojedynczego dokumentu (który może być bardzo złożony)
- transakcje nie są obsługiwane
- w razie potrzeby twórcy MongoDB sugerują używanie "pseudotransakcji"

Pseudotransakcje w MongoDB





przykład z http://cookbook.mongodb.org/patterns/perform-two-phase-commits/

 stworzenie obiektu transakcji w stanie initial i pola pendingTransactions we właściwych obiektach

zmiana stanu obiektu transakcji na pending

Pseudotransakcje w MongoDB 2





 wykonanie operacji skojarzonych z transakcją, gdy stan transakcji jest pending

```
foo:PRIMARY> db.accounts.update({name: t.source, pendingTransactions: {$ne: t._id}}, {$inc: (balance: -t.value}, $push: {pendingTransactions: t._id}}) foo:PRIMARY> db.accounts.update({name: t.destination, pendingTransactions: {$ne: t._id}}, {$inc: {balance: t.value}, $push: {pendingTransactions: t._id}}) foo:PRIMARY> db.accounts.find() { "_id": ObjectId("4d7bc97fb8a04f5126961523"), "balance": 900, "name": "A", "pendingTransactions": [ ObjectId("4d7bc7a8b8a04f5126961522") ] } { "_id": ObjectId("4d7bc984b8a04f5126961524"), "balance": 1100, "name": "B", "pendingTransactions": [ ObjectId("4d7bc7a8b8a04f5126961522") ] }
```

zmiana stanu transakcji na committed

```
foo:PRIMARY> db.transactions.update({_id: t._id}, {$set: {state: "committed"}})
foo:PRIMARY> db.transactions.find()
{ "_id" : ObjectId("4d7bc7a8b8a04f5126961522"), "destination" : "B", "source" : "A", (state" : "committed") "value" : 100 }
```

usunięcie informacji o pendingTransaction we właściwych obiektach

zmiana stanu transakcji na done

```
foo:PRIMARY> db.transactions.update({_id: t._id}, {$set: {state: "done"}})
foo:PRIMARY> db.transactions.find()
{ "_id" : ObjectId("4d7bc7a8b8a04f5126961522"), "destination" : "B", "source" : "A", "state" : "done", "value" : 100 }
```

Kolekcje z danymi o określonym czasie trwania





 dla kolekcji można ustawić TTL (Time To Live), a po określonym czasie mongod automatycznie usuwa przeterminowane dane

```
db.log.events.ensureIndex( { "status": 1 }, { expireAfterSeconds: 3600 } )
```

Pole *status* musi zawierać datę/timestamp. MongoDB sprawdza to pole by określić czy dana jest przeterminowana czy nie

- kiedy przydatne?
 - logi, informacje sesyjne
- dostępne od wersji MongoDB 2.2

Server-side commands





funkcja z dużą interakcją z bazą danych

```
update_area = function() {
    db.phones.find().forEach(
        function(phone) {
        phone.components.area++;
        phone.display = "+"+
            phone.components.country+" "+
            phone.components.area+"-"+
            phone.components.number;
        db.phone.update({ _id : phone._id }, phone, false);
      }
    )
    przykład
```

wywołanie funkcji JS po stronie serwera

```
> db.eval(update_area)
```

przykład za Seven Databases in Seven Weeks

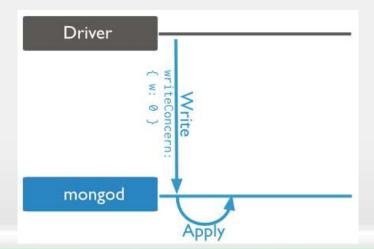
- zalety
 - wydajność
- wady
 - blokowanie demona mongod podczas wykonywania kodu JS (!!!)
 używać tylko do administracyjnych zadań, gdy nikt nie korzysta z bazy

Write concern



- określa gwarancje dot. raportowania sukcesu na operacjach zapisu
- typy: unacknowledged, acknowledged, journaled, replica acknowledged
- unacknowledged

za http://docs.mongodb.org/manual/core/write-concern/



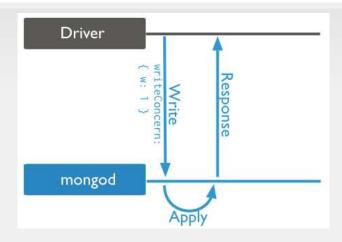
Write concern 2



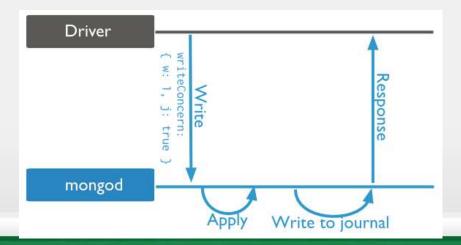


acknowledged

 domyślny tryb w nowszych driverach



journaled

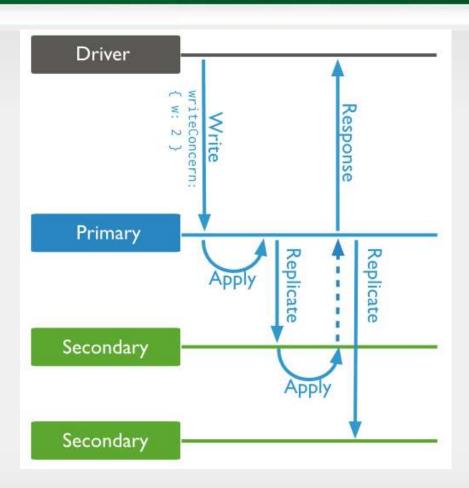


Write concern 3





replica acknowledged



jak zmienić?

mongoClient.setWriteConcern(WriteConcern.JOURNALED);

GridFS



- specyfikacja dedykowana do zapisywania i odczytywania plików przekraczających dopuszczalny rozmiar dokumentów BSON 16MB, zwłaszcza do zapisywania plików binarnych
- można używać do dowolnych dokumentów (są one dzielone i przetrzymywane w postaci chunks)

Jak korzystać z GridFS w Javie?





przykład za http://blog.rezajp.info/posts/how-to-write-or-read-images-to-or-from-mongodb-gridfs/

zapis

```
public String saveImage(byte[] content,String fileName,String contentType) {

// create a table/collection or use the existing one
GridFS gfsPhoto = new GridFS(mongoTemplate.getDb(), "photo");

GridFSInputFile gfsFile = gfsPhoto.createFile(content);

gfsFile.setFilename(fileName);
gfsFile.setContentType(contentType);
gfsFile.save();

return gfsFile.getId().toString();
}
```

odczyt

```
GridFS gfsPhoto = new GridFS(mongoTemplate.getDb(), "photo");
GridFSDBFile image = gfsPhoto.findOne(new ObjectId(id));
InputStream stream = image.getInputStream();
```

Backup



- mongodump i mongorestore narzędzia do tworzenia backupu (hot backup) i przywracania z niego bazy
- mongoexport i mongoimport eksport i import
 JSON, CSV i TSV (tab separated values)
 - przykład dla importu w json:

```
mongoimport --db <dbname> --collection <collname> --type json --file <file>
```

Bazy dokumentowe





- Zalety
 - wydajność
 - schema-less
 - dobrze się skalują
- Wady
 - brak powiązania między polami => dane mogą łatwo stać się niespójne
 - redundantność danych

Kiedy warto używać MongoDb?





- nie ma stałego schematu danych
- high write load
- wymagania dot. dużej dostępności
 - **•** ?
- b.duża ilość danych (skalowanie relacyjnych baz danych jest trudniejsze)
 - **–** [
- caching

Best practices





- unikaj negacji w zapytaniach przy indeksach rzadkich
 - w takim przypadku MongoDB nie indeksuje braku wartości, więc warunek negacji może wymagać przeskanowania wszystkich rekordów
- używaj polecenia explain()
 - analogicznie do Explain Plan z relacyjnych baz
- korzystaj z indeksów
 - i zapytań, które korzystają z indeksów sprawdzaj zapytania poleceniem explain()
- zapewnij uniform distribution of shard keys
- range-based sharding wymaga dobrej znajomości zapytań i danych, łatwiej użyć hash-based sharding

Literatura



- P. J. Sadalage, M. Fowler, NoSQL Distilled: A Brief Guide to the Emerging World of Polyglot Persistence, ..., 2013
- K.Banker, MongoDB in Action, Manning 2012
- E.Redmond, J.Wilson, Seven Databases in Seven Weeks, The Pragmatic Bookshelf 2012
- K.Chodorow, MongoDB: The Definitive Guide, O'Reilly 2013
- R.Copeland, MongoDB: Applied Design Patterns, O'Reilly 2013
- K.Seguin, The Little MongoDB Book (available online: http://openmymind.net/mongodb.pdf)
- K.Chodorow, 50 Tips & Tricks for MongoDB Developers, O'Reilly 2011
- K.Chodorow, Scaling MongoDB, O'Reilly 2011

Laboratorium





 tworzenie zapytań oraz implementacja kodu w Javie do interakcji z MongoDB